# Uso del script en Colaboratory

## Introducción

- Colaboratory es un entorno gratuito de Jupyter Notebook que no requiere configuración y que se ejecuta completamente en la nube.
- Es un Jupyter Notebook (JN) almacenado en Google Drive. Estos cuadernos están compuestos de celdas que pueden contener código, texto e imágenes entre otros elementos. Podremos ejecutar código Python sin necesitar una instalación específica en nuestro ordenador.
- Podemos utilizar un JN y guardar una copia en Drive. (Archivo/guardar una copia en Drive).
- Para poder utilizar Colaboratory es necesario tener abierta una cuenta de Google (la cuenta del correo de la Universidad bastaría).
- https://colab.research.google.com/notebooks/welcome.ipynb

# Para acelerar la ejecución

- Activar la ejecución en TPU o GPU

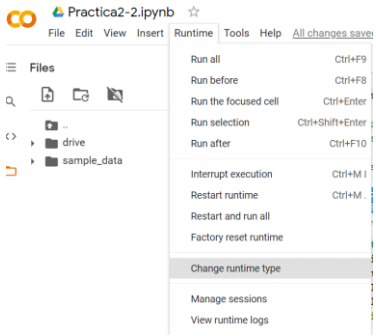


3

# Importar librerías

- Se trabajará con Keras que es una librería de alto nivel, escrita en Python, que utiliza la librería de más bajo nivel TensorFlow.
- Fue desarrollada para poder hacer experimentación de una forma muy rápida (prototipado).
- Importaremos TensorFlow, ciertos módulos de Keras , librerías de Python para hacer plots y ciertos módulos de la librería de aprendizaje automático scikit-learn que nos permitirá obtener las matrices de confusión y otros informes de una manera muy sencilla

```
import tensorflow as tf
import numpy as np

from tensorflow.keras import datasets, layers, models
import matplotlib.pyplot as plt

#Confusion Matrix and classification report
from sklearn.metrics import  confusion_matrix, classification_report
```

4

# Conjunto de datos a utilizar

- Utilizaremos el conjunto de datos CIFAR10

- 60000 imágenes en color
- 10 clases
- 6000 imágenes por clase
- Entrenamiento: 50000 imágenes
- Test: 10000 imágenes
- Cada imagen: 32 x 32 pixels y 3 canales (RGB)

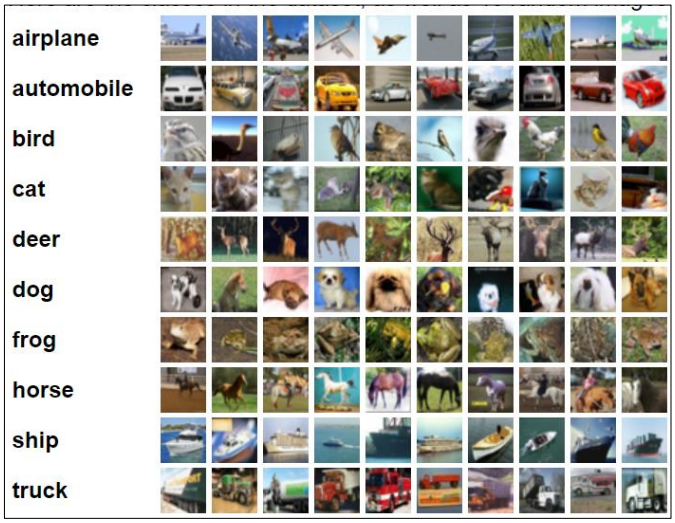


5

# Descargar los datos

- Obtendremos las imágenes de entrenamiento (`train_images`) y las de test (`test_images`) así como las salidas, es decir, las etiquetas correspondientes (`train_labels` y `test_labels`)

```
(train_images, train_labels), (test_images, test_labels) = datasets.cifar10.load_data()
```

```
Downloading data from https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz
170500096/170498071 [==============================] - 2s 0us/step
```

6

# Ver la estructura de los datos

```
#print the structure of data
print(train_images.shape)
print(test_images.shape)
print(train_labels.shape)
print(train_labels[1])
```

```
(50000, 32, 32, 3)
(10000, 32, 32, 3)
(50000, 1)
[9]
```

- Las imágenes son arrays de cuatro dimensiones (50000,32,32,3)
  - número de imágenes, anchura en pixels, altura en pixels, número de canales
- Las etiquetas se representan por un valor entero entre 0 y 9 (10 clases)

7

# Ver algunas imágenes

- Representaremos las primeras 25 imágenes de entrenamiento

```
class_names = ['airplane', 'automobile', 'bird', 'cat', 'deer',
               'dog', 'frog', 'horse', 'ship', 'truck']

plt.figure(figsize=(7,7))
for i in range(25):
    plt.subplot(5,5,i+1)
    plt.xticks([])
    plt.yticks([])
    plt.grid(False)
    plt.imshow(train_images[i], cmap=plt.cm.binary)
    # The CIFAR labels happen to be arrays,
    # which is why you need the extra index
    plt.xlabel(class_names[train_labels[i][0]])
plt.show()
```

8

# Ver algunas imágenes

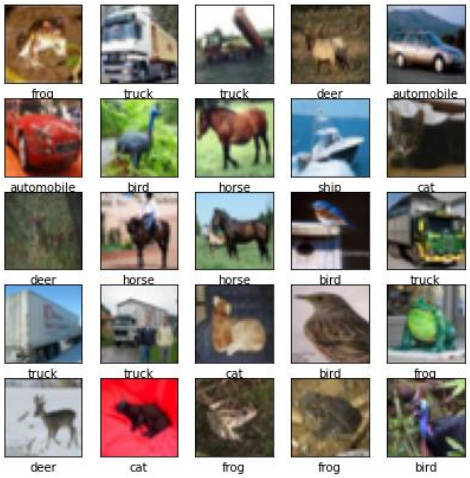


9

# Definir los modelos de redes de neuronas. PM

- En esta sección definimos cada modelos utilizando Keras, mediante una función en Python. Podemos definir tantas funciones como queramos y luego utilizaremos la que nos convenga en cada caso.
- Usaremos un modelo secuencial y vamos añadiendo capas
- Ejemplo de PM muy básico
  - Aplicamos una normalización a la entrada (los píxeles podrían tener valores entre 0 y 255)
  - La capa de entrada tendrá 32 x 32 x 3 neuronas. Mediante *Flatten*, la estructura matricial se aplana en un vector de entradas
  - Añadimos una capa oculta de 50 neuronas con función de activación sigmoidal (podremos usar otras funciones como 'tanh', 'relu', etc.
  - La última capa tendrá 10 neuronas (una por clase) con función de activación 'softmax'. Es una función similar a la sigmoide pero normalizada de forma que todas las salidas suman 1. Así se podrá corresponder cada valor con una probabilidad.

```
def create_simple_pm():
    #modelo simple de pm:
    model = tf.keras.models.Sequential()
    model.add(tf.keras.layers.BatchNormalization(input_shape=(32, 32, 3)))
    model.add(tf.keras.layers.Flatten(input_shape=(32, 32, 3), name="Input_layer"))
    model.add(tf.keras.layers.Dense(50, activation='sigmoid', name="Hidden_layer"))
    model.add(tf.keras.layers.Dense(10, activation='softmax', name="Output_layer"))
    return model
```

10

# Definir CNN. Capa convolucional

- Las CNN tendrán capas convolucionales, capas de 'pooling' y capas 'fully connected'
- Capa de convolución: para imágenes se utiliza la convolución 2D. En Keras utilizamos la función conv2D
  - (https://keras.io/layers/convolutional/)
- Argumentos más importantes de conv2D

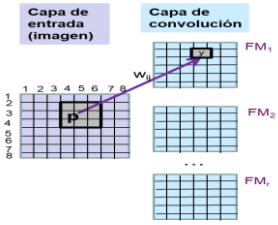


- **filters**: número de filtros
- **kernel_size**: tamaño de los filtros. Ej: (3,3), (5,5), etc
- **activation**: función de activación
- **strides**: los saltos que da el filtro. Por defecto vale 1.
- **Padding:** se utiliza para mantener la dimensión de la imagen que recibe la capa de convolución, añadiendo pixels a 0 alrededor de la imagen. Puede ser 'valid' o 'same'. Valor por defecto 'valid', que equivale a no utilizar padding. Si es 'same' se añaden pixels con valor 0 alrededor de la imagen para que la anchura y altura de la salida sean las mismas.

Ejemplo: `model.add(layers.Conv2D(16, (3, 3), activation='relu',padding='same'))`

núm de filtros

tam de los filtros

11

# Definir CNN. Capa de 'pooling'

Capa de Pooling

- Sirve para reducir el tamaño de la representación. Ej, con maxPooling:

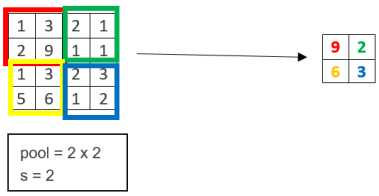


- Las capas de pooling no tienen parámetros (pesos) solo tienen hiperparámetros
- Las capas de pooling siempre mantienen el número de canales
  Se aplican a cada canal por separado
- Por defecto, el valor de strides coincide con pool_size, y no se solapan las ventanas.
- Esta capa reduce a la mitad la anchura y altura del input.
- Ejemplo: `model.add(layers.MaxPooling2D((2, 2)))`
  por defecto, strides = (2,2)

12

# Definir CNN. Capa 'fully connected'

- Son capas de un perceptron multicapa convencional, donde todas las neuronas de una capa se conectan con todas las de la capa siguiente.

**Funciones de Keras:**

- **Flatten**: realiza el aplanado de las neuronas de la capa anterior. Equivale a la capa de entrada de un PM.
  Ejemplo: `model.add(layers.Flatten())`
- **Dense :** Añade una capa con un determinado número de neuronas
  Ejemplo: Capa con 32 neuronas y función de activación 'relu'
  `model.add(layers.Dense(32, activation='relu'))`
- Habría que añadir la última capa con 10 neuronas (una por clase) y con función de activación 'softmax'

```
model.add(layers.Dense(10, activation='softmax'))
```

13

# Definir CNN

- Ejemplo de una red CNN muy simple: normalización, capa convolucional con 16 filtros de 3 x 3. La FullyConnected con 32 neuronas ocultas y 10 neuronas de salida

```
def create_model_simple_cnn():
  model = models.Sequential()
  model.add(layers.BatchNormalization(input_shape=(32, 32, 3)))
  model.add(layers.Conv2D(16, (3, 3), activation='relu',padding='same'))
  model.add(layers.MaxPooling2D((2, 2)))

  model.add(layers.Flatten())
  model.add(layers.Dense(32, activation='relu'))
  model.add(layers.Dense(10, activation='softmax'))
  return model
```

14

# Incluir Dropout en los modelos

- Dropout: se eliminan neuronas (y por tanto los pesos asociados) con una determinada probabilidad p, para prevenir el sobreaprendizaje. Si p=0.75, la probabilidad de eliminar neuronas es (1-P=0.25)
  - Valores altos de p, se eliminan pocas
  - Valores pequeños de p, se eliminan muchas

```
def create_model_simple_cnn():
  model = models.Sequential()
  model.add(layers.BatchNormalization(input_shape=(32, 32, 3)))
  model.add(layers.Conv2D(16, (3, 3), activation='relu',padding='same'))
  model.add(layers.Dropout(0.75))
  model.add(layers.MaxPooling2D((2, 2)))
  model.add(layers.Flatten())
  model.add(layers.Dense(32, activation='relu'))
  model.add(layers.Dropout(0.75))
  model.add(layers.Dense(10, activation='softmax'))
  return model
```

```
def create_simple_pm():
    #modelo simple de pm:
    model = models.Sequential()
    model.add(layers.BatchNormalization(input_shape=(32, 32, 3)))
    model.add(layers.Flatten(input_shape=(32, 32, 3), name="Input_layer"))
    model.add(layers.Dense(50, activation='sigmoid', name="Hidden_layer"))
    model.add(layers.Dropout(0.75))
    model.add(layers.Dense(10, activation='softmax', name="Output_layer"))
    return model
```

15

# Crear y visualizar el modelo

- Una vez definidas las funciones, creamos el modelo mediante una llamada a la función que nos interese

```
model = create_model_simple_cnn()
#model = create_simple_pm()
```

- Podemos visualizar la arquitectura del modelo creado

```
model.summary()
```

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
batch_normalization_4 (Batch (None, 32, 32, 3)         12
_________________________________________________________________
conv2d_4 (Conv2D)            (None, 32, 32, 16)        448
_________________________________________________________________
max_pooling2d_4 (MaxPooling2 (None, 16, 16, 16)        0
_________________________________________________________________
flatten_4 (Flatten)          (None, 4096)              0
_________________________________________________________________
dense_8 (Dense)              (None, 32)                131104
_________________________________________________________________
dense_9 (Dense)              (None, 10)                330
=================================================================
Total params: 131,894
Trainable params: 131,888
Non-trainable params: 6
```

16

# Compilar el modelo

- Debemos compilar el modelo mediante el método ***compile***
- Debemos especificar:
  - El **optimizador** a utilizar (Adam, RMSprop, Adagrad, etc.)
  - La función objetivo a minimizar (**loss**): Utilizaremos como función loss '**sparse_categorical_crossentropy**', apropiada para problemas de clasificación multiclase, ya que no es necesario transformar la salida o target de los datos para igualar el número de neuronas de salida del modelo. Basta con un número entero que indique la clase del dato correspondiente.
  - La métrica a utilizar para medir el rendimiento de la red. La más adecuada para un problema de clasificación es '**sparse_categorical_accuracy**'

```
model.compile(
      optimizer=tf.keras.optimizers.Adam(learning_rate=1e-3, ),
      #optimizer=tf.keras.optimizers.RMSprop(learning_rate=0.001, rho=0.9),
      loss='sparse_categorical_crossentropy',
      metrics=['sparse_categorical_accuracy'])
```

17

# Entrenar el modelo

- Finalmente, entrenamos el modelo mediante el método ***fit***
- Debemos pasar como argumento los datos de entrenamiento y los de test, así como especificar:
  - El número de épocas o iteraciones (`epochs`)
  - Opcionalmente, el número de batches por época (`steps_per_epoch`) o el tamaño de cada batch (`batch_size`). Si no se especifican, se toman valores por defecto. Consultar https://keras.io/api/models/model_training_apis/
    - En cada batch se actualizan los pesos.
  - Cada cuantas épocas se ejecuta una validación (`validation_freq`)
    Si `validation_freq=1` se valida al finalizar cada época.

18

# Entrenar el modelo

- Recopilamos toda la información generada durante el entrenamiento y la guardamos en 'historico'

```
historico = model.fit(train_images, train_labels, epochs=10, validation_freq=1,
                      validation_data=(test_images, test_labels))
```

```
Epoch 1/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.7610 - sparse_categorical_accuracy: 0.7332
Epoch 2/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.7340 - sparse_categorical_accuracy: 0.7431
Epoch 3/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.7178 - sparse_categorical_accuracy: 0.7472
Epoch 4/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.6974 - sparse_categorical_accuracy: 0.7553
Epoch 5/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.6783 - sparse_categorical_accuracy: 0.7603
Epoch 6/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.6592 - sparse_categorical_accuracy: 0.7662
Epoch 7/10
1563/1563 [==============================] - 5s 3ms/step - loss: 0.6433 - sparse_categorical_accuracy: 0.7714
Epoch 8/10
```

19

# Generar plots de evolución del entrenamiento

- Generamos plots de la evolución de 'loss' y 'accuracy'

```
# summarize history for loss
plt.plot(historico.history['loss'])
plt.plot(historico.history['val_loss'])
plt.title('model loss')
plt.ylabel('loss')
plt.xlabel('epoch')
plt.legend(['train', 'test'], loc='upper left')
plt.show()

# summarize history for accuracy
plt.plot(historico.history['sparse_categorical_accuracy'])
plt.plot(historico.history['val_sparse_categorical_accuracy'])
plt.title('model accuracy')
plt.ylabel('accuracy')
plt.xlabel('epoch')
plt.legend(['train', 'test'], loc='upper left')
plt.ylim([0, 1])
plt.show()
```

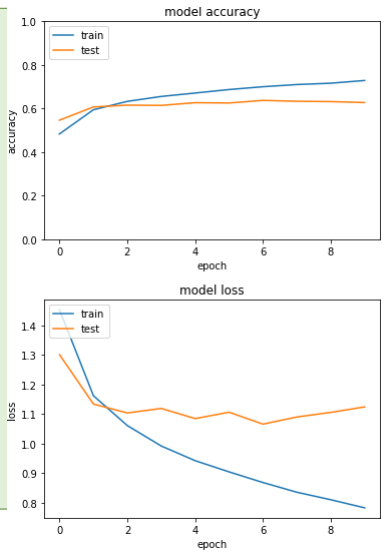

# Evaluar el modelo y obtener predicciones

- Evaluar el modelo:

```
evaluacion=model.evaluate(test_images, test_labels)
```

```
313/313 [==============================] - 1s 2ms/step - loss: 1.1052 - sparse_categorical_accuracy: 0.6475
```

- Obtener predicciones en bruto

```
#predicciones en bruto:
raw_testPred = model.predict(test_images)
#prediccion en bruto de los 10 primeros patrones de test: 10 vectores de valores reales
print(raw_testPred[:10])
```

```
[[7.41690106e-04 3.56358760e-05 5.43894188e-04 9.83913779e-01
  5.89337107e-03 7.48885854e-04 2.06495961e-03 2.59268127e-05
  5.98397804e-03 4.78074217e-05]
 [3.66786931e-04 1.39174744e-01 2.75374550e-08 2.96261438e-09
  1.04141513e-08 2.58799260e-10 1.48812476e-10 3.89624062e-11
  8.60219181e-01 2.39213085e-04]
```

21

# Obtener predicciones por clase y matriz de confusión

- Para obtener predicciones con la clase asignada

```
#predicciones de la clase:
class_testPred = np.argmax(raw_testPred, axis=1)
#predicción de la clase de los 10 primeros patrones de test
print(class_testPred[:10])
```

```
[3 8 8 0 4 6 1 6 3 1]
```

- Obtener la matriz de confusión

```
#Confusion Matrix

cm=confusion_matrix(test_labels, class_testPred)
print(cm)
```

```
[[698  40  60  28  13   8   5  10  82  56]
 [ 29 801  12  13   6   2   6   9  16 106]
 [ 77  14 531  70 101  59  62  48  21  17]
 [ 29  30  95 497  73 130  68  41  19  18]
 [ 42   6  88  77 578  29  72  82  18   8]
 [ 18  12  97 230  54 462  38  67  11  11]
 [ 18  20  59  81  54  20 726   5   9   8]
 [ 30  18  43  47  53  46  13 720   4  26]
 [ 94  75  17  15   4   4   3   4 717  67]
 [ 46 134  10  19   6   4   5  26  23 727]]
```

22

# Obtener classification report

- Puede obtenerse un informe completo desglosado por clase (no es necesario para esta práctica)

```
print('Classification Report')
target_names = ['airplane', 'automobile', 'bird', 'cat', 'deer',
                'dog', 'frog', 'horse', 'ship', 'truck']
print(classification_report(test_labels, class_testPred, target_names=target_names))
```

```
Classification Report
              precision    recall  f1-score   support

    airplane       0.65      0.70      0.67      1000
  automobile       0.70      0.80      0.75      1000
        bird       0.52      0.53      0.53      1000
         cat       0.46      0.50      0.48      1000
        deer       0.61      0.58      0.60      1000
         dog       0.60      0.46      0.52      1000
        frog       0.73      0.73      0.73      1000
       horse       0.71      0.72      0.72      1000
        ship       0.78      0.72      0.75      1000
       truck       0.70      0.73      0.71      1000

    accuracy                           0.65     10000
   macro avg       0.65      0.65      0.64     10000
weighted avg       0.65      0.65      0.64     10000
```

23

# Guardar los resultados en ficheros

- Evolución de `loss` y `accuracy` de entrenamiento y test y la matriz de confusión

```
#guardar resultados
np.savetxt('evaluacion.txt',evaluacion,newline='\t')
np.savetxt('historicoTrainLoss.txt',historico.history['loss'])
np.savetxt('historicoTestLoss.txt',historico.history['val_loss'])
np.savetxt('historicoTrainAcc.txt',historico.history['sparse_categorical_accuracy'])
np.savetxt('historicoTestAcc.txt',historico.history['val_sparse_categorical_accuracy'])
# guardar matriz de confusión
np.savetxt('matrizConf.txt', cm, fmt='%-3d')
```

- Guardar el modelo

```
#guarda el modelo completo
model.save('modelo.h5')
#guarda solo pesos
model.save_weights('pesos.h5')
```

Se pueden ver los archivos de la carpeta actual. Se pueden descargar en nuestro explorador de ficheros o realizar una copia en Drive

24